

Tech Challenge IADT — Fase 1

Entrega completa — Câncer de Mama (Wisconsin)

Repositório:

https://github.com/lucianoft/machine_learning_cancer_mama

Conteúdo: relatório técnico · arquitetura · gráficos EDA · métricas · prints API

Índice do documento

Seção	Conteúdo
1	Mapa dos entregáveis
2	Arquitetura do sistema (diagrama)
3	Relatório técnico resumido
4	Gráficos do notebook (EDA e modelos)
5	Tabelas e métricas (saídas do notebook)
6	Prints da API REST (Swagger / Postman)

Mapa dos entregáveis — Fase 1

Exigência	Arquivo / link
Repositório Git	https://github.com/lucianoft/machine_learning_cancer_mama
Código-fonte	api/, models/, notebook
README	README.md
Dockerfile	Dockerfile + docker-compose.yml
Dataset	breast_cancer_wisconsin.csv
Gráficos e prints	Seções 4–6 deste PDF
Arquitetura	ARQUITETURA.md + diagrama
Relatório técnico	RELATORIO_TECNICO.md

Arquitetura do sistema

O sistema segue fluxo em camadas: dataset → notebook (treino) → pipeline serializada (.pkl) → API FastAPI em Docker → cliente (Swagger/Postman). O mesmo pré-processamento do treino é aplicado em produção via joblib.




Diagrama de arquitetura — dados, ML, API e clientes

Componente	Tecnologia	Função
Notebook	Jupyter + sklearn	EDA, treino, avaliação
Pipeline	joblib .pkl	Imputer + Scaler + Regressão Logística
API	FastAPI	Endpoints /health, /metadata, /predict
Deploy	Docker	Container porta 8000

Relatório técnico — resumo

EDA

569 amostras, 30 features de núcleos celulares (PAAF). 62,7% benignas, 37,3% malignas. Sem missing values.

Pré-processamento

SimpleImputer(median) → StandardScaler → Classificador. Split 80/20 estratificado.

Modelos

Modelo	
Logistic Regression	95,4%
Random Forest	92,4%
KNN	93,6%
Decision Tree	88,4%

Modelo em produção: Logistic Regression (maior F1-Score).

Gráficos e análises (notebook)

Saídas de Tech_Challenge_Breast_Cancer.ipynb — EDA, matriz de confusão e comparação de modelos.




Figura 1 — Distribuição da variável alvo (benigno vs maligno)




Figura 2 — Histogramas das variáveis numéricas




Figura 3 — Pairplot das medidas mean_* por diagnóstico




Figura 4 — Matriz de correlação entre features




Figura 5 — Matriz de confusão (Regressão Logística)




Figura 6 — Comparação de modelos por F1-Score

Tabelas e métricas (saídas do notebook)

1. Carregamento dos dados

```
.dataframe tbody tr th:only-of-type { vertical-align: middle; } .dataframe tbody tr th { vertical-align: top; } .datafra
```

1. Carregamento dos dados

2. Analise Exploratoria (EDA)

```
.dataframe tbody tr th:only-of-type { vertical-align: middle; } .dataframe tbody tr th { vertical-align: top; } .datafra
```

2. Analise Exploratoria (EDA)

2. Analise Exploratoria (EDA)

```
.dataframe tbody tr th:only-of-type { vertical-align: middle; } .dataframe tbody tr th { vertical-align: top; } .datafra
```

2. Analise Exploratoria (EDA)

6. Avaliacao de um modelo de classificacao

```
.dataframe tbody tr th:only-of-type { vertical-align: middle; } .dataframe tbody tr th { vertical-align: top; } .datafra
```

6. Avaliacao de um modelo de classificacao

7. Comparacao de algoritmos

Modelo	Accuracy	Recall	F1-Score
0 Logistic Regression	0.973684	0.952381	0.963855
2 Random Forest	0.973684	0.928571	0.962963
3 K-Nearest Neighbors	0.956140	0.904762	0.938272
1 Decision Tree	0.903509	0.833333	0.864198

7. Comparacao de algoritmos

9. Teste de carga da pipeline (simulando API REST)

```
.dataframe tbody tr th:only-of-type { vertical-align: middle; } .dataframe tbody tr th { vertical-align: top; } .datafra
```

9. Teste de carga da pipeline (simulando API REST)

Prints da API REST

Documentação Swagger, requisição POST /predict e respostas JSON.

Print — Swagger UI (<http://localhost:8000/docs>)

Tech Challenge — Câncer de Mama (Breast Cancer Wisconsin)

GET /health — Status da API
 GET /metadata — Metadados do modelo
 POST /predict — Classificação benigno/maligno

POST /predict — Request body (application/json):
 { "patient": { "mean radius": ..., ... 30 campos } }

Responses: 200 — PredictResponse
 predicao, label, probabilidade_benigno, probabilidade_maligno

Print 1 — Documentação Swagger (/docs)

Print — Postman POST /predict (request + response)

POST <http://localhost:8000/predict>
 Content-Type: application/json

Body (exemplo benigno):

```
{
  "patient": {
    "mean radius": 13.54,
    "mean texture": 14.36,
    "mean perimeter": 87.46,
    "mean area": 566.3,
    "mean smoothness": 0.09779,
    "mean compactness": 0.08129,
    "mean concavity": 0.06664,
    "mean concave points": 0.04781,
    "mean symmetry": 0.1885,
    "mean fractal dimension": 0.05766,
    "radius error": 0.2699,
    "texture error": 0.7886,
    "perimeter error": 2.058,
    "area error": 23.56,
    "smoothness error": 0.008462,
    "compactness error": 0.0146,
    "concavity error": 0.02387,
    "concave points error": 0.01315,
    "symmetry error": 0.0198,
    "fractal dimension error": 0.0023,
    "worst radius": 15.11,
    "worst texture": 19.26,
    "worst perimeter": 99.7,
    "worst area": 711.2,
    "worst smoothness": 0.144,
    "worst compactness": 0.1773,
    "worst concavity": 0.239,
    "worst concave points": 0.1288,
    "worst symmetry": 0.2977,
    "worst fractal dimension": 0.07259
  }
}
```

Response 200 OK:

```
{
  "predicao": 0,
  "label": "Benigno",
  "probabilidade_benigno": 0.9092,
  "probabilidade_maligno": 0.0908
}
```

Print 2 — Postman: requisição e resposta da API

Print — GET /health e GET /metadata

GET http://localhost:8000/health

Response:

```
{  
  "status": "ok",  
  "model_name": "Logistic Regression"  
}
```

GET http://localhost:8000/metadata

Response (trecho):

```
model_name: "Logistic Regression"  
feature_columns: [30 medidas PAAF]  
target_labels: { "0": "Benigno", "1": "Maligno" }
```

Print 3 — Endpoints de sistema