

Tech Challenge IADT — Fase 2

Projeto 1 — Otimização de Modelos de Diagnóstico (Câncer de Mama)

Conteúdo: arquitetura · algoritmo genético (codificação, operadores, experimentos, comparativo) · integração com LLM (Groq/OpenAI) · avaliação de qualidade · observabilidade · testes automatizados · prints reais da API.


Mapa dos entregáveis — Fase 2

Exigência	Onde está
Algoritmo genético (codificação, operadores, fitness)	ga/ — search_space.py, individual.py, operators.py, fitness.py
≥3 experimentos com configs diferentes	ga/run_ga_experiments.py + reports/ga_experiments_results.csv
Comparativo otimizado vs. original	reports/ga_vs_baseline.csv (seção 4 deste PDF)
Monitoramento e logging	api/observability.py — logging estruturado + /metrics (Prometheus)
Documentação de arquitetura	ARQUITETURA.md + docs/arquitetura_sistema.png
Integração com LLM + prompt engineering	llm/ — prompts.py, explainer.py
Avaliação da qualidade das explicações	llm/evaluation.py + reports/llm_evaluation.csv
Ambiente virtual	requirements.txt / requirements-api.txt / requirements-dev.txt + venv
Testes automatizados	tests/ (pytest) — 25 testes
Relatório técnico	RELATORIO_TECNICO.md

Arquitetura do sistema

Fluxo: dataset → algoritmo genético (offline, ≥3 experimentos) → pipeline otimizada → API FastAPI em Docker → clientes (Swagger/Postman) e LLM (Groq/OpenAI) para explicação em linguagem natural. Observabilidade via logging estruturado e métricas Prometheus.

Arquitetura — Câncer de Mama (GA + LLM + API REST)



Algoritmo genético — otimização de hiperparâmetros

Codificação (representação de genes)

Cada indivíduo é um *dict* {hiperparâmetro: valor} — não uma bitstring. Decodificado direto pros kwargs do classificador sklearn.

Modelo	Genes	Motivo
logistic_regression (em produção na Fase 1)	C (log-float 0.001–100) penalty (l1/l2)	Modelo já servido — comparação direta antes/depois
random_forest (2º lugar na Fase 1)	n_estimators, max_depth, min_samples_split, min_samples_leaf, max_features	Espaço de busca mais rico

Operadores

Seleção: torneio (k=3). **Crossover:** uniforme por gene (cada gene do filho vem de um dos pais com 50% de chance). **Mutação:** resample — cada gene tem probabilidade `mutation_rate` de ser resorteadado dentro dos limites do espaço de busca. **Elitismo:** os 2 melhores indivíduos de cada geração passam direto.

Função fitness

```
fitness = 0.25 · accuracy + 0.45 · recall + 0.30 · f1  
(avaliado por StratifiedKFold cv=3 no TREINO — nunca no teste)
```


Recall pesa mais porque falso negativo (maligno classificado como benigno) é o erro mais grave nesse contexto clínico.

Experimentos (≥ 3 configurações)


Modelo	Experimento	Pop.	Mutação	Fitness CV	F1 teste
logistic_regression	baseline_ga	16	0.1	0.9669	0.9762
logistic_regression	populacao_maior	32	0.1	0.9684	0.9762
logistic_regression	mutacao_alta	16	0.35	0.9684	0.9762
random_forest	baseline_ga	16	0.1	0.9519	0.9512
random_forest	populacao_maior	32	0.1	0.9518	0.9630
random_forest	mutacao_alta	16	0.35	0.9532	0.9512


Convergência — logistic_regression

Convergencia GA — logistic_regression






Convergencia GA — logistic_regression





Convergência — random_forest



Comparativo: otimizado vs. original

Baseline recalculado no mesmo treino/teste (não copiado do relatório da Fase 1), com os hiperparâmetros exatamente como no notebook original.

Modelo	Acc. original	Recall original	F1 original	Acc. GA	Recall GA	F1 GA
logistic_regression	97.4%	95.2%	96.4%	98.2%	97.6%	97.6%
random_forest	97.4%	92.9%	96.3%	97.4%	92.9%	96.3%

Vencedor: logistic_regression — ganho real de F1 (96,4% → 97,6%) e recall (95,2% → 97,6%, menos falsos negativos). Hiperparâmetros: {'C': 0.640067, 'penalty': 'l2'}. Pipeline salva em models/pipeline_breast_cancer_ga_optimized.pkl, servida pela API por padrão.

Integração com LLM

Abordagem

POST /predict/explain roda a mesma predição do /predict e manda o resultado pra uma LLM (llm/explainer.py), que devolve explicação em linguagem natural. Provedor configurável via LLM_PROVIDER=groq|openai (default groq — API compatível com a da OpenAI, gratuita, servindo Llama 3, um dos modelos sugeridos no PDF do desafio). As features citadas na explicação são as 5 com maior |z-score| em relação à média de treino (via o StandardScaler já treinado na pipeline) — o que há de mais atípico naquela amostra específica.

Exemplo real — amostra benigna (POST /predict/explain, resposta ao vivo)

```
predicao: 0 (Benigno)
probabilidade_benigno: 0.9037
probabilidade_maligno: 0.0963
```

explicacao:

O resultado do modelo de classificação indica que a amostra de núcleo celular é provável de ser benigna, com uma probabilidade de 90,4%. Isso sugere que a lesão pode não ser cancerígena. As características mais relevantes da amostra que contribuíram para essa predição incluem a textura média (14,36) e a textura pior (19,26), que podem estar relacionadas à aparência e à estrutura do tecido.

Além disso, a dimensão fractal média (0,05766) também foi considerada pelo modelo, o que pode indicar a complexidade da estrutura do tecido. Essas características, em conjunto, apontam para uma probabilidade mais alta de a lesão ser benigna. No entanto, é importante notar que a probabilidade de a lesão ser maligna não é zero, com 9,6% de chance.

É fundamental lembrar que esse resultado é apenas uma ferramenta de apoio à decisão e não substitui a avaliação médica, mamografia, ultrassonografia nem biopsia. O profissional de saúde tem a palavra final. Ferramenta de apoio a decisao. Nao substitui avaliacao medica, mamografia, ultrassonografia nem biopsia. O profissional de saude tem a palavra final.

Exemplo real — amostra maligna (POST /predict/explain, resposta ao vivo)

```
predicao: 1 (Maligno)
probabilidade_maligno: 1.000000
```

explicacao:

O resultado do modelo de classificação indica que a amostra é provável de ser maligna, com uma probabilidade de 100,0%. Isso sugere que as características da amostra apresentam padrões consistentes com tumores cancerígenos.

Algumas das medidas mais relevantes da amostra que contribuíram para essa predição incluem a "worst symmetry" (0,4601), que pode indicar uma forma irregular do núcleo celular, e a "worst compactness" (0,6656), que pode sugerir uma densidade celular anormal. Além disso, a "mean concavity" (0,3001) também foi considerada, o que pode indicar uma invaginação ou retração na forma do núcleo.

É importante lembrar que esse resultado é apenas uma ferramenta de apoio à decisão e não substitui a avaliação médica. Ferramenta de apoio a decisao. Nao substitui avaliacao medica, mamografia, ultrassonografia nem biopsia. O profissional de saude tem a palavra final.

Avaliação da qualidade das explicações

8 casos representativos do teste (benigno/maligno, confiança alta/baixa), gerados de verdade via `llm/evaluation.py`.

Caso	Label real	Label predito	Confiança	Contém disclaimer
190	Maligno	Maligno	52.6%	True
205	Maligno	Maligno	55.0%	True
455	Benigno	Maligno	60.5%	True
456	Benigno	Benigno	66.8%	True
393	Maligno	Maligno	100.0%	True
219	Maligno	Maligno	100.0%	True
563	Maligno	Maligno	100.0%	True
503	Maligno	Maligno	100.0%	True

Nota: caso 455 é uma predição incorreta do modelo (real=Benigno, previsto=Maligno, confiança 60,5%) — mantido no relatório de propósito, pra mostrar que a explicação da LLM reflete honestamente o que o modelo previu, mesmo quando o modelo erra. Colunas de clareza e correção clínica (1–5) ficam pra revisão manual — ver `RELATORIO_TECNICO.md`.

Testes automatizados

Suíte pytest — API (TestClient, LLM mockada), ModelService, operadores e fitness do GA, explainer (OpenAI/Groq mockado).

```
$ pytest -q
..... [100%]
25 passed, 10 warnings in 3.89s
```

Prints da API REST (respostas reais)

GET /health

```
{
  "status": "ok",
  "model_name": "logistic_regression (otimizado via algoritmo genetico)"
}
```

POST /predict

```
{
  "predicao": 0,
  "label": "Benigno",
  "probabilidade_benigno": 0.9036752769505358,
  "probabilidade_maligno": 0.09632472304946411
}
```

Documentação completa (Swagger): <http://localhost:8000/docs> — endpoints /health, /metadata, /predict, /predict/explain, /metrics.

Referências

UCI ML Repository — Breast Cancer Wisconsin (Diagnostic)

Kaggle — Breast Cancer Wisconsin (Diagnostic)

Tech Challenge IADT — Fase 2 (IADT - Fase 2 - Tech challenge.pdf)

Groq API docs: <https://console.groq.com/docs>

OpenAI API docs: <https://platform.openai.com/docs>